

Scrapy // فریمورک وب کراولینگ ناهمگام

توپولوژی راکتور غیرمسدودکننده، جبر استخراج با سلکتورها، الگوریتم AutoThrottle و کانفیگ پایدار

۰.۱. آناتومی معماری و چرخه جریان داده (Data Flow)

ماشین حالت متناهی و حلقه رخداد غیرمسدودکننده Twisted / Asyncio

موتور اسکریپی جریان داده میان صف زمان‌بندی، دالودر غیرهمگام شبکه و لایه‌های پایپ‌لاین را بدون قفل کردن پردازش‌ها هماهنگ می‌کند.

موتور مرکزی

هماهنگ‌کننده

زمان‌بند صف

حذف تکراری‌ها

دالودر

واکنش HTTP

اسپایدرها

پارسی XPath/CSS

پایپ‌لاین اقلام

ذخیره در DB

۰.۲. گرامر دستورات و جدول ماتریس CLI

مستقل

دستورات سراسری سیستم

دستور	مثال دستوری	عملکرد سیستمی
shell	<code>scrapy shell "<url>" --nolog</code>	محیط تعاملی REPL برای ارزیابی سلکتورها.
fetch	<code>scrapy fetch --headers "<url>"</code>	دریافت سند خام HTTP با دالودر داخلی.
view	<code>scrapy view "<url>"</code>	بررسی رندر صفحه در مرورگر برای تست JS.
runspider	<code>scrapy runspider single_spider.py</code>	اجرای مستقیم فایل پایتون بدون پروژه.

محیط کاری

دستورات قلمرو پروژه

دستور	مثال دستوری	عملکرد سیستمی
crawl	<code>scrapy crawl sp -O out.jsonl</code>	اجرای اسپایدر و استریم به فایل خروجی.
parse	<code>scrapy parse --spider=sp <url></code>	تست واحد کالیک‌های اسپایدر به طور مجزا.
genspider	<code>scrapy genspider -t crawl name site.com</code>	تولید قالب اولیه اسپایدر از روی الگو.
check	<code>scrapy check <spider_name></code>	بررسی اعتبارسنجی قراردادهای (Contracts).

مبتنی بر lxml در C

موتور انتخاب‌گرها: مقایسه XPath 1.0 و CSS3

هدف استخراج	ساختار نحو CSS3	معادل استاندارد XPath 1.0	مزیت و نکات فنی
مقدار ویژگی (Attribute)	<code>a::attr(href)</code>	<code>//a/@href</code>	پشتیبانی XPath از توابع <code>starts-with()</code> و <code>contains()</code>
استخراج متن گره	<code>div.title::text</code>	<code>//div[@class='title']/text()</code>	تجميع بازگشتی متون نودهای فرزند با <code>string(//div)</code>
پیمایش معکوس والد	غیرقابل پشتیبانی	<code>//input[@id='x']/ancestor::form</code>	پیمایش دوطرفه در کل گراف DOM بدون وابستگی به درخت.
استخراج با ریجکس	<code>css('h1::text').re(r'\d+')</code>	<code>xpath('//h1/text()').re_first(r'\d+')</code>	تطبيق مستقیم الگو بدون تخصیص حافظه اضافه در پایتون.

۰۳. موتور کنترل تطبیقی AutoThrottle و جدول عیب‌یابی

عیب‌یابی	جدول عیب‌یابی و سناریوهای بحرانی	منطق الگوریتم AutoThrottle
خطای 403 کلودفلر	استفاده از پروکسی مسکونی، هدرهای Sec-CH یا درایور Playwright.	میزان تأخیر دانلود را به طور پویا بر اساس تأخیر پاسخ‌دهی (Latency) سرور مقصد تنظیم می‌کند.
خطای Reactor	فراخوانی <code>asyncio reactor.install()</code> قبل از ایمپورت راکتور.	۱. محاسبه تأخیر: محاسبه زمان رفت و برگشت (RTT) هر پاسخ HTTP. ۲. هدف‌گذاری هم‌روندی: حفظ ضریب <code>AUTOTHROTTLE_TARGET_CONCURRENCY</code> . ۳. فرمول تأخیر: <code>delay = latency / target_concurrency</code> . ۴. بازه امنیتی: محدودسازی بین مقادیر <code>START_DELAY</code> و <code>MAX_DELAY</code> . ۵. واکنش به ترافیک بالا: افزایش آنی تأخیر در صورت دریافت کدهای 503 یا 429.
نشت رم و خطای OOM	تنظیم <code>DEPTH_PRIORITY = 1</code> و فعال‌سازی <code>MEMUSAGE_LIMIT_MB</code> .	
تایم‌اوت DNS	فعال‌سازی <code>DNSCACHE_ENABLED = True</code> و کاهش <code>DOWNLOAD_TIMEOUT</code> .	

۰۴. فایل تنظیمات بهینه‌شده برای محیط عملیاتی (settings.py)

```
# =====
# PhTex High-Performance Production Scrapy settings.py (Light Theme Build)
# =====
TWISTED_REACTOR = "twisted.internet.asyncioreactor.AsyncioSelectorReactor"
CONCURRENT_REQUESTS = 32 # حداکثر چرخه‌های هم‌روند شبکه در حلقه رخداد
CONCURRENT_REQUESTS_PER_DOMAIN = 16
DOWNLOAD_TIMEOUT = 15 # پیشگیری از قفل شدن پورت‌های معلق شبکه

# کنترل تطبیقی و هوشمند نرخ ارسال درخواست‌ها
AUTOTHROTTLE_ENABLED = True
AUTOTHROTTLE_START_DELAY = 1.0
AUTOTHROTTLE_MAX_DELAY = 10.0
AUTOTHROTTLE_TARGET_CONCURRENCY = 2.0

# تاب‌آوری در برابر خطاهای سرور و حفاظت از رم سرور
RETRY_ENABLED = True
RETRY_TIMES = 3
RETRY_HTTP_CODES = [500, 502, 503, 504, 522, 524, 408, 429]
MEMUSAGE_ENABLED = True # سیستم عامل OOM-killer بستن ایمن پروسه قبل از فرخوانی
MEMUSAGE_LIMIT_MB = 2048

# فیلتر درخواست‌های تکراری DNS کش داخلی تفکیک آدرس
DNSCACHE_ENABLED = True
DNSCACHE_SIZE = 10000
REQUEST_FINGERPRINTER_IMPLEMENTATION = "2.7"
DUPEFILTER_CLASS = "scrapy.dupefilters.RFPDupeFilter"

DEFAULT_REQUEST_HEADERS = {
    "Accept": "text/html,application/xhtml+xml,application/xml;q=0.9,*/*;q=0.8",
    "Accept-Language": "fa-IR,fa;q=0.9,en-US;q=0.8,en;q=0.7",
    "Upgrade-Insecure-Requests": "1",
}
```