

Scrapy // ربات جمع‌آوری اطلاعات از وبسایت‌ها

چگونه بدون ساعت‌ها کپی‌پیست دستی، اطلاعات هزاران صفحه وب را در چند ثانیه داخل اکسل بریزیم؟

۰۱. اصل داستان به زبان ساده: اسکرپینگ چیست؟

فرض کنید می‌خواهید قیمت و نام ۱,۰۰۰ تا کالا را از یک سایت یادداشت کنید.

روش دستی: باید هزار بار کلیک کنید، متن را کپی کنید، اکسل را باز کنید و پیست کنید. این کار هفته‌ها وقت می‌گیرد و خسته‌کننده است.

روش جادویی با Scrapy: اسکرپی یک ربات کوچک است؛ آدرس سایت را به او می‌دهید و در عرض ۳۰ ثانیه تمام صفحات را می‌خواند، قیمت‌ها و کلمات را جدا می‌کند و یک فایل شیک اکسل تحویل‌تان می‌دهد!

۰۲. نصب و راه‌اندازی کارگاه ربات در خط فرمان کامپیوتر

۱ نصب ربات (با یک خط)

پنجره سیاه (خط فرمان یا CMD) را باز کنید، دستور زیر را تایپ کنید و کلید **Enter** را بزنید:

```
pip install scrapy
```

✓ بعد از ۱ دقیقه ربات آماده به کار روی کامپیوتر شما نصب می‌شود.

۲ ساخت کارگاه پروژه

پروژه جدید

برای ساخت پوشه پروژه‌تان، در همان پنجره تایپ کنید:

```
scrapy startproject mybot
```

یک پوشه به نام **mybot** ساخته می‌شود که تمام ابزارها داخل آن است.

۰۳. کد ساده عنکبوت جمع‌آوری‌کننده (Spider چیست؟)

داخل پوشه **mybot/spiders/** یک فایل متنی با نام **quotes.py** بسازید و این کد چنخطی را داخل آن قرار دهید:

```
import scrapy

class QuotesSpider(scrapy.Spider):
    name = "quotes" # نام این ربات
    start_urls = ["https://quotes.toscrape.com"] # آدرس سایت مقصد

    def parse(self, response):
        # پیدا کردن هر جعبه متن و برداشتن عنوان و نام نویسنده
        for item in response.css("div.quote"):
            yield {
                "text": item.css("span.text::text").get(),
                "author": item.css("small.author::text").get(),
            }
```

۰۴. زدن دکمه استارت و تحویل گرفتن فایل اکسل

دستوری که در خط فرمان تایپ می‌کنید

چه نتیجه‌ای حاصل می‌شود؟

ربات بیدار می‌شود، سایت را در ۳ ثانیه اسکن می‌کند و تمام داده‌ها را داخل فایلی به نام **results.csv** می‌ریزد.

```
scrapy crawl quotes -o results.csv
```

وقتی با ماوس روی فایل کلیک کنید، برنامه **Excel** باز شده و جدول تمیز را می‌بینید!

یک محیط آزمایشی باز می‌کند تا قبل از ذخیره کردن، تست کنید که آیا کدهای صفحه درست انتخاب می‌شوند یا خیر.

```
scrapy shell "آدرس سایت"
```

۰۵. جلوگیری از مسدود شدن ربات توسط سایت‌ها (سرعت ایمن)

اگر سایتی ببیند در ۱ ثانیه ۱۰۰ صفحه باز شده، فکر می‌کند حمله شده و ربات را قفل می‌کند (خطای ۴۰۳). برای اینکه ربات با ادب و شبیه انسان با فاصله زمانی صفحات را باز کند، در فایل **settings.py** این خط را بگذارید:

```
AUTOTHROTTLING_ENABLED = True
```

با این یک خط، ربات خودکار بین هر صفحه ۱ ثانیه صبر می‌کند تا هیچ‌وقت مسدود نشود.

مسیر پوشه: [HpTex/scrapy/fa/](#)

مجموعه مرجع کاربردی HpTex — مستندات استاندارد برای همه